Informe de validación — Modelo de PD de crédito al consumo

Home Credit Default Risk · 25/10/2026 · Marco: SR 26-2 (estructura de validación de SR 11-7) · Proyecto de portfolio

Resultado: APROBADO CON CONDICIONES

Modelo XGBoost + calibración Platt + PD de grado con margen de conservadurismo, 164 features, test de 61.503 solicitudes no usadas para entrenar. Gini 0,518 (IC95% 0,503–0,532), KS 0,383, ECE 0,004. El modelo ordena bien el riesgo y está calibrado en promedio, pero presenta observaciones de fairness y de monotonía que condicionan su uso: ver hallazgos y challengers propuestos.

Checks cuantitativos

Check	Valor	Umbral	Estado
gini	0,5176	>= 0,2	PASS
ks	0,3825	>= 0,15	PASS
lift_benchmark	0,0214	> 0	PASS
ece	0,0045	<= 0,02	PASS
citl	-0,016	|x| <= 0,1	PASS
master_scale	ninguno	sin grados en rojo (Jeffreys p < 1%)	PASS
psi	0,0002	<= 0,25	PASS
fairness	ver hallazgos	DPD ≤ 0,10 · DIR ≥ 0,80 · gap EO ≤ 0,10	FAIL

Hallazgos y recomendaciones

MEDIA **Flags de fairness en age_group [FAIR-age_group]**

DPD 0,151 supera 0,1; TPR gap 0,319 supera 0,1; FPR gap 0,124 supera 0,1. DIR 0,847 (regla 4/5 cumplida).
→ Decisión de negocio/legal documentada sobre el uso de la edad; ver hallazgo NB03-1 sobre el canal de los scores de bureau.

reports/fairness_report.json

MEDIA **Discriminación menor en segmentos [VAL-SEG]**

<25 (Gini 0,464), >55 (Gini 0,422), Pensioner (Gini 0,445) vs 0,518 global.
→ Monitorear Gini por segmento; revisión manual o modelo específico si se usa para pricing.

reports/model_validation.json → segment_performance; notebook 03 §3.4

MEDIA **PD no monótona respecto del monto solicitado [NB04-1]**

En ~36% de los clientes, pedir más monto (con cuota y valor del bien proporcionales) baja la PD. El modelo aprendió una correlación de selección, no una relación causal.
→ Resuelto en los challengers M1/M3 (monotone_constraints + credit_goods_ratio en lugar de AMT_GOODS_PRICE): violación 0%, a un costo de ~0,5–0,9 puntos de Gini. Ver reports/challengers.json.

notebooks/04_robustez_counterfactuals.ipynb §4.2

MEDIA **Impacto diferencial por edad transmitido por los scores de bureau [NB03-1]**

Los menores de 35 están sobre-representados en los rechazos incorrectos de alta confianza (ratio 1,8–2,3). SHAP muestra que la causa son los EXT_SOURCE (EXT_SOURCE_1 tiene correlación 0,60 con la edad), no la variable edad.
→ Revisión manual de jóvenes rechazados cerca del cutoff; documentar la justificación de negocio; evaluar fuentes alternativas para clientes con poco historial.

notebooks/03_error_analysis.ipynb §3.3, notebooks/01_eda.ipynb §1.4

MEDIA **Calibración desigual por género [NB07-1]**

Con el género fuera del modelo, la PD subestima a los hombres (9,2% vs 10,2% observado, −9,6%) y sobreestima a las mujeres (+4,4%). Es el trade-off entre fairness through unawareness y calibración por grupo.
→ Documentar la decisión de política; monitorear la calibración por género junto con DIR/DPD.

notebooks/07_advanced_validation.ipynb §1

BAJA **Remediación aplicada: PD de grado con margen de conservadurismo [VAL-MOC]**

Con la PD individual el backtest fallaba en la cola (grado G: Jeffreys p 0,010 → 0,679; grado F: Jeffreys p 0,047 → 0,258). La PD de grado = máx(PD media, percentil 75 de Jeffreys del default observado en validación) corrige la subestimación; la pérdida esperada sube +5,2%.
→ Re-estimar el MoC en cada recalibración y backtestearlo semestralmente; la PD individual sigue usándose para ordenar y decidir.

models/champion/grade_pd.json; src/models/moc.py

BAJA **Ganancia moderada sobre los benchmarks [VAL-BENCH]**

Gini XGBoost 0,518 vs logística 0,496 (+0,021) y scorecard WoE 0,482 (+0,036).
→ Si la interpretabilidad pesa más que ~3–4 puntos de Gini, el scorecard es una alternativa defendible.

reports/scorecard.json

Hallazgos (continuación)

BAJA **Challenger recomendado: M3_monotonico_pagos [CH-1]**

Gini 0,528 (Δ +0,011 vs champion, IC95% pareado [+0,005; +0,016]), monótono en el monto, ECE 0,004 y backtest por grado sin rojos con MoC.
→ Promoverlo a candidato a champion en el próximo ciclo, con validación completa (fairness, estabilidad y análisis de errores).

reports/challengers.json; src/models/challengers.py

BAJA **El cutoff por break-even usa la TEA nominal [NB02-1]**

Con TEAs nominales altas (Argentina 80%, Brasil 59%) la regla aprueba al 99,9%. No descuenta inflación, fondeo ni costos operativos.
→ Modelar el margen neto real por mercado antes de usar la regla fuera de USA.

notebooks/02_threshold_analysis.ipynb §2.4

BAJA **Decisiones frágiles cerca del cutoff [NB04-2]**

Con ruido de ±5% en las variables de entrada, la decisión cambia en el 27% de los clientes a menos de 3 pp del cutoff (contra el 0,6% lejos del cutoff).
→ Banda de revisión manual de ±3 pp alrededor del cutoff (~5% de las solicitudes).

notebooks/04_robustez_counterfactuals.ipynb §4.1

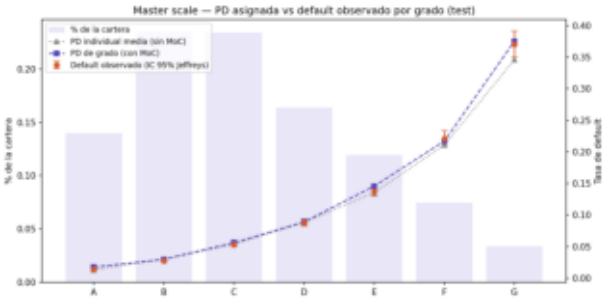
BAJA **La información de pagos anteriores es incremental [NB06-1]**

El stack XGBoost + LSTM llega a Gini 0,530 (+0,013). Variables agregadas simples de installments_payments dentro de XGBoost (challenger M2) logran 0,534: la misma ganancia sin red recurrente.
→ Preferir las variables agregadas (M2/M3) al LSTM; ver challenger recomendado.

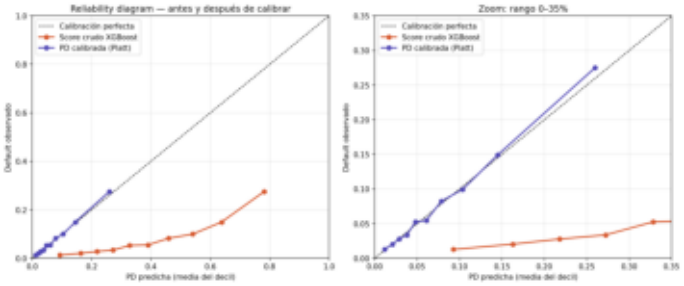
notebooks/06_deep_learning.ipynb §3; reports/challengers.json

Evidencia

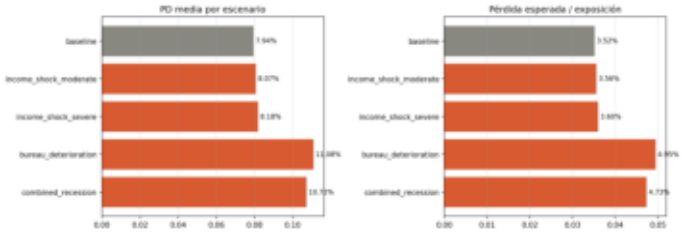
Backtest por grado (master scale)



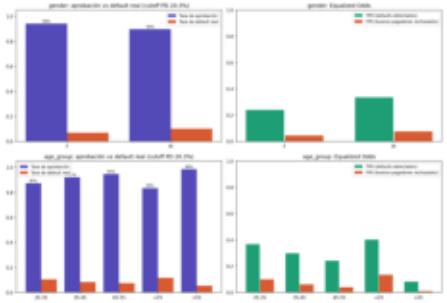
Calibración: score crudo vs PD calibrada



Stress test: PD y pérdida esperada



Fairness con la regla de decisión



Limitaciones

• Stress test: el escenario más severo (bureau_deterioration) sube la pérdida esperada +41%; el modelo es poco sensible a shocks de ingreso (+1,1% con ingreso −25%) y muy sensible a los scores de bureau.

• Sin dimensión temporal: no hay validación out-of-time; el PSI train/test sólo mide homogeneidad del split.

• El TARGET no equivale a una definición regulatoria de default ni tiene horizonte de 12 meses (no apto para IFRS 9 sin ajustes).

• Validación hecha por el mismo autor del modelo: no hay validación independiente (effective challenge).

• Sólo application_train: bureau y previous_application quedan como próximo paso.